SinOdio / SansHaine

Clasificador automático de discurso de odio en español
(con extensión prevista al francés)

Ariane Heinz Vallribera

KeepCoding Bootcamp | Big Data, Inteligencia Artificial & Machine Learning | Edición XVI | Abril 2026

XLM-RoBERTa · FastAPI · Google Cloud Run · BigQuery · PowerBI

Incremento del odio en España, Francia y Europa (2016 - 2024)

Media anual 2016-2024	Total delitos 2024	Total delitos 2016-2024	Crecimiento 2024 vs media anual
372	460	3,2K	31%

Nota: Los datos provienen de reportes oficiales y de organizaciones no gubernamentales, por lo que infraestiman la magnitud real del problema y dependen de la situación política de cada estado.

Distribución de delitos de odio en Europa (2016-2024)

Datos de la Organización para la Seguridad y Cooperación en Europa

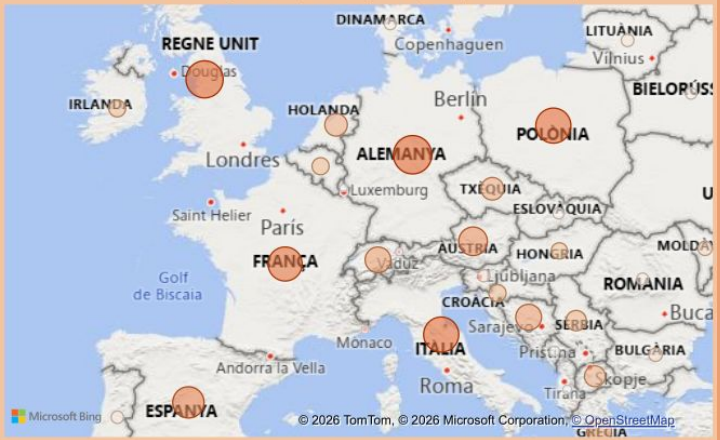

Tipo de incidentes de odio en España vs Francia

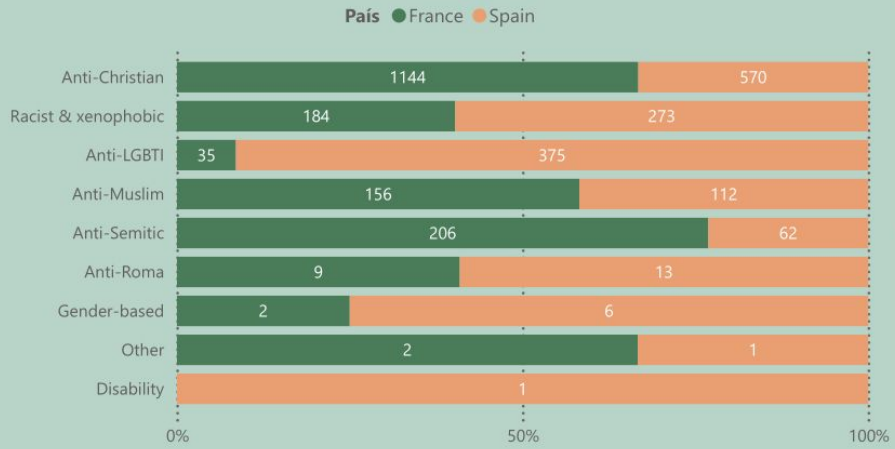

Evolución de los delitos de odio (2016-2024)

Motivación

3.151

incidentes de odio registrados
en España y Francia (2016–2024)

Fuente: OSCE/ODIHR Hate Crime Reporting

2024: año con más incidentes en Francia (333), y también subiendo en España

¿Por qué necesitamos detección automática?

- El volumen de contenido en redes sociales hace imposible la moderación manual
- Brecha entre delitos oficiales y los reportados por ONGs: los números reales son mucho mayores
- 10 estados de la OSCE no cumplen su compromiso básico de registrar delitos de odio
- Las categorías más afectadas en España: Anti-Cristiano, Anti-LGBTI, Racismo/Xenofobia
- Herramienta de apoyo para ONGs que trabajan contra el odio en línea

El problema técnico

Clasificación binaria

Dado un texto en español, predecir:

¿discurso de odio (1) o no (0)?

Lenguaje implícito

El odio no siempre usa insultos explícitos; también puede existir (y es más difícil de detectar), en metáforas, humor, ideología sin agresión directa

Diversidad dialectal

Español peninsular + latinoamericano (chileno).

Múltiples registros y plataformas

Ejemplo difícil: "Las mujeres no deberían tener derecho a votar" → el modelo lo clasifica como no-odio (94% confianza)
*El **odio ideológico** sin lenguaje agresivo explícito es más difícil de detectar*

Dataset & EDA

Dataset	Fuente	Ejemplos	% Odio	Registro
Superset	Twitter (ES/LA)	29.855	24,3%	Insultos explícitos
DETOXIS	Noticias (ES)	3.463	33,1%	Xenofobia argumentativa
HAHA	Humor (ES)	24.000	38,6%	Odio implícito/humor
TOTAL fusionado	**3 fuentes**	**57.088**	**30,8%**	**Heterogéneo**

Hallazgos clave del EDA

- Sesgo dialectal: fuerte presencia de español chileno en el Superset ("ctm", "weones") — vulgaridades sin intención ofensiva
- Hipótesis no confirmada: menciones @USER no discriminan entre clases (media idéntica) → el odio está en el semántico, no en la estructura
- Textos de odio más cortos en Twitter, más largos en DETOXIS (comentarios argumentativos de hasta 3.270 caracteres)
- Sin solapamiento entre Superset y los otros dos datasets → sin riesgo de data leakage entre train/test

Arquitectura del sistema

HuggingFace Datasets
3 datasets
57k ejemplos

Cloud Storage
Raw + processed
Parquet

XLM-RoBERTa
VM GCP
NVIDIA L4

FastAPI Docker
Cloud Run
200MB image

BigQuery
Métricas
resultados

PowerBI Dashboard
Visualización
business

API REST — sinodio-api-1064831214069.europe-west4.run.app

```
GET  /              → Información general del proyecto
GET  /health        → Estado del servicio y modelo cargado
POST /predict       → Clasificación de texto individual + probabilidades
POST /predict-batch → Hasta 50 textos + resumen estadístico
```

Baseline de Machine Learning tradicional

Pipeline

1. Limpieza de texto
Eliminación de @USER, URLs, artefactos HTML

2. TF-IDF
Unigramas + bigramas + trigramas | 42k tokens | min_df=2

3. Modelos
Regresión Logística | Random Forest | class_weight='balanced'

4. Optimización
Optuna (50 trials LR, 30 trials RF) | métrica: F1 macro

F1 macro: media armónica de precisión y recall, calculada por clase y ponderada con pesos idénticos (penaliza modelos que funcionan bien en una clase pero mal en la otra → importante cuando las clases no están equilibradas)

Resultados en test

Métrica	Log. Reg.	Rand. Forest
F1 Macro ★	0,745	0,744
Accuracy	0,775	0,782
Precision	0,739	0,745
Recall	0,754	0,743

✓ Modelo seleccionado: Regresión Logística

Mayor recall en clase de odio (0,70 vs 0,64)
Entrena en segundos vs ~40 min del RF

Fine-tuning de XLM-RoBERTa

Arquitectura del modelo

- XLM-RoBERTa base: 12 capas · 768 dim · 100 idiomas
- Cabeza personalizada: 768 → 256 (ReLU) → 2
- Dropout p=0,3 antes de cada capa lineal
- 278 millones de parámetros entrenables
- Token [CLS] como representación de secuencia

Entrenamiento

- VM GCP: n1-standard-4 + GPU NVIDIA L4 (23,7 GB)
- Optuna coarse-to-fine: lr=4,41e-5 · batch=32
- 5 epochs · AdamW · warmup lineal · checkpointing
- MAX_LENGTH=128 tokens · truncación 0,3% del corpus
- Imagen Docker CPU (~200 MB) en Cloud Run

Evolución del entrenamiento

Epoch	1	2	3	4	5 ★
Train Loss	0,5127	0,3858	0,3061	0,2244	0,1538
Val F1	0,7483	0,7957	0,8038	0,8066	0,8072

La función de pérdida de entrenamiento continúa descendiendo al finalizar ⇨ el modelo podría beneficiarse de 1-2 epochs adicionales

SinOdio / SansHaine – Resultados del modelo

Regresión Logística	XLM-RoBERTa	Regresión Logística	XLM-RoBERTa
F1 Macro (test)	F1 Macro (test)	Recall (test)	Recall (test)
0,745	0,810	0,75	0,807

Resultados completos por modelo y split

Model	Split	Accuracy	Precision	Recall	F1 Macro
Logistic Regression	val	0,776	0,738	0,749	0,743
Logistic Regression	test	0,776	0,739	0,754	0,745
Random Forest	val	0,778	0,740	0,741	0,740
Random Forest	test	0,782	0,745	0,743	0,744
XLM-RoBERTa	val	0,836	0,809	0,806	0,807
XLM-RoBERTa	test	0,840	0,814	0,807	0,810

Rendimiento por métrica y modelo

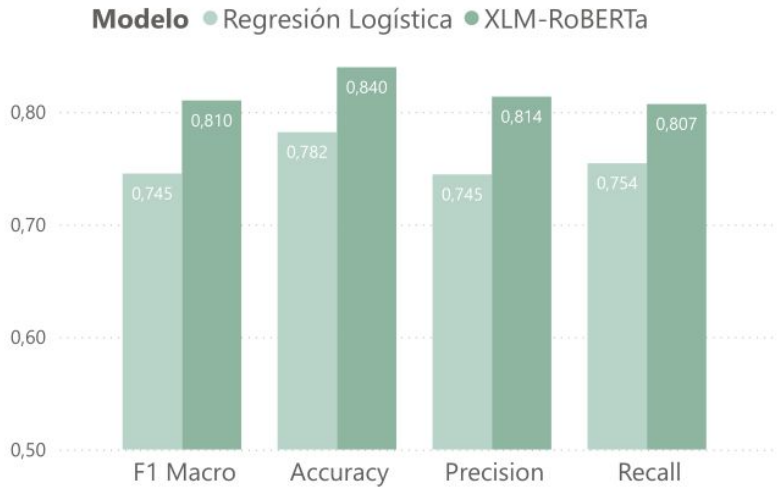

XLM-RoBERTa mejora el F1 macro del baseline en 6,5 puntos porcentuales (0,745 → 0,810)

Distribución de clases

Conjunto de entrenamiento

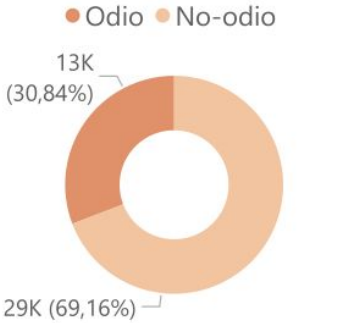

Matriz de confusión

XLM-RoBERTa (test)

Real \ Pred	No-odio	Odio
No-odio	5271	651
Odio	740	1902

Resultados comparados

XLM-RoBERTa mejora el F1 macro en +6,5% respecto al baseline (0,745 → 0,810)

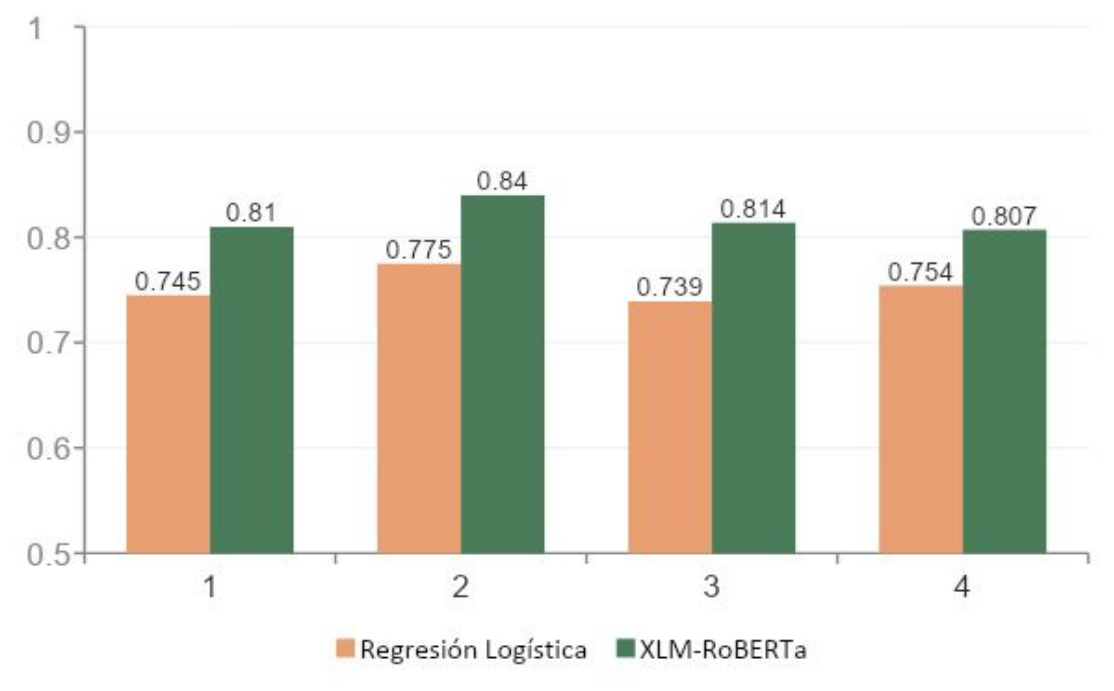

Matriz de confusión — XLM-RoBERTa (test)

Real \ Pred	No-odio	Odio
No-odio	**5.271**	651
Odio	740	**1.902**

TN=5.271 · FP=651 · FN=740 · TP=1.902

	Precisión	Recall	F1
No-odio	0,88	0,89	0,89
Odio ★	0,75	0,72	0,74

Demo — API en producción

https://sinodio-api-1064831214069.europe-west4.run.app/docs

Ejemplos de clasificación en tiempo real

"Ojalá que todos los inmigrantes se vayan de aquí"	**ODIO**	90,45%
"Estos refugiados son una plaga para nuestro país"	**ODIO**	54,95%
"Hoy ha sido un día tranquilo en el parque"	**NO ODIO**	99,82%
"Las mujeres no deberían tener derecho a votar"	**NO ODIO** ⚠️	94,47%

⚠️ *El modelo falla en **odio ideológico** sin lenguaje agresivo explícito* ➡ *limitación documentada, base para trabajo futuro*

Conclusiones, limitaciones y trabajo futuro

Qué funciona

✓ XLM-RoBERTa: F1 macro 0,810 | mejora de +6,5pp sobre baseline

✓ Corpus heterogéneo (Twitter + noticias + humor) → representaciones robustas

✓ API REST en producción | escalable | coste ≈ 0 sin tráfico

✓ Arquitectura preparada para extensión a francés sin cambios en el modelo

Limitaciones

✗ Odio ideológico sin lenguaje agresivo: baja detección

✗ Sesgo latinoamericano (chileno) en el Superset

✗ Sin lematización en pipeline TF-IDF

Trabajo futuro

→ Fase 2: extensión al francés (CONAN + OLID-FR)

→ Fase 3: clasificador multiclase por grupo objetivo

→ HuggingFace Spaces: demo pública con Gradio

¿Qué haría diferente?

Configurar permisos IAM desde el inicio | usar scikit-learn Pipelines | aprovisionamiento Standard desde el principio

SinOdio / SansHaine

Porque las palabras hacen daño, y la tecnología puede ayudar a detectarlas

API en producción:
sinodio-api-1064831214069.europe-west4.run.app

Repositorio GitHub:
https://github.com/AriadnaHV/Fighting-Hate-Speech

Swagger UI / Demo:
sinodio-api-1064831214069.europe-west4.run.app/docs

¡Gracias!

Ariane Heinz Vallribera | KeepCoding Bootcamp | Big Data, Inteligencia Artificial & Machine Learning | Edición XVI | Abril 2026